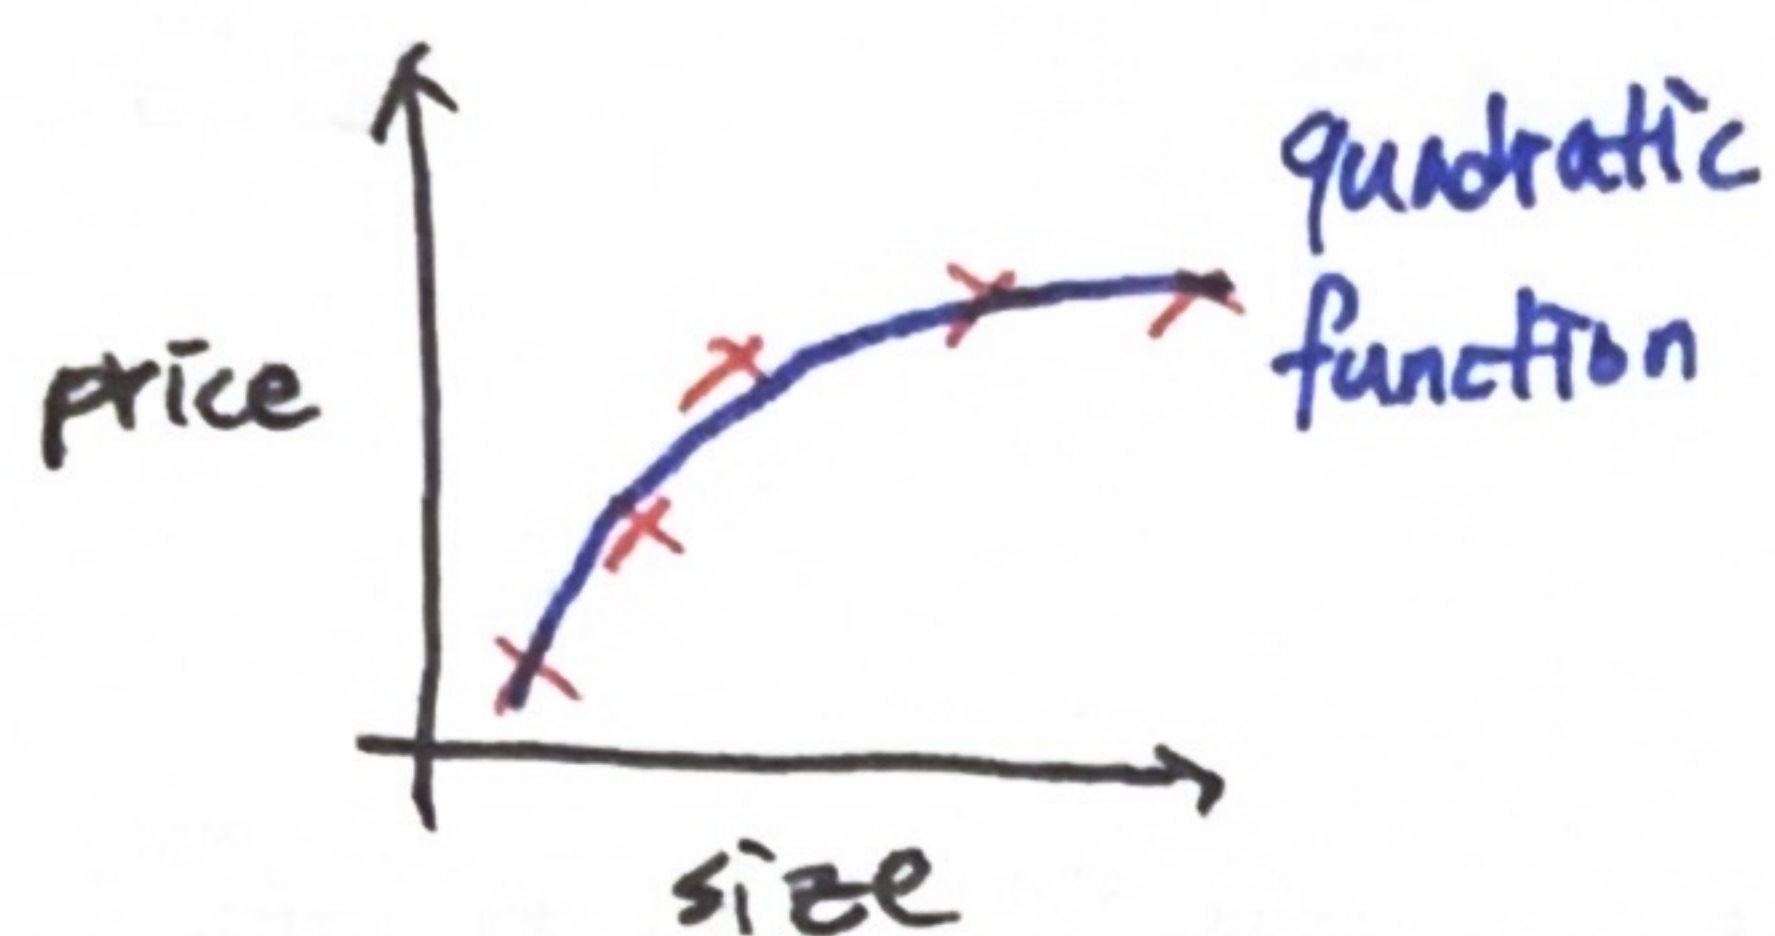



< Cost Function with Regularization >



$$w_1x + w_2x^2 + b$$

↓

"generalization"



$$w_1x + w_2x^2 + w_3x^3 + w_4x^4 + b$$

↓

"overfitting"

- w_3, w_4 를 0에 가까운 수로 만들 수 있다면 overfitting된 모델을 quadratic function 모델처럼 만들 수 있음

⇒ w_3, w_4 에 penalty를 부여함으로써 overfitting 방지

Objective: make w_3, w_4 really small (≈ 0)

$$\min_{\vec{w}, b} \frac{1}{2m} \sum_{i=1}^m (f_{\vec{w}, b}(\vec{x}^{(i)}) - y^{(i)})^2 + 1000 w_3^2 + 1000 w_4^2 \quad (w_3 \approx 0, w_4 \approx 0)$$

- linear regression의 squared error cost function 아님

- w_3, w_4 에 큰 값 (eg. 1000)을 곱함으로써 w_3, w_4 의 값이 크다면 cost value가 커지게 되는 것을 방지하며 penalty를 부여해준다

- 위 cost function이 작은 값을 갖기 위해서는 w_3, w_4 값이 매우 작아야함 (≈ 0)

- w_3, w_4 를 매우 작은 값으로 minimize 함으로써 4차함수 모델(overfit)을 사용하더라도 (= 모든 feature를 사용하더라도) 2차함수 모델(generalized)에 거의 근접하도록 할 수 있음

* 만약 feature 수가 너무 많아 어떤 parameter (w_j)를 minimize 해야할지 모를 때?

⇒ "모든 feature에 적용하는 parameter들에 penalty를 부여"

= 모든 feature를 사용하더라도 overfitting을 방지 = "Regularization"

$$J(\vec{w}, b) = \frac{1}{2m} \sum_{i=1}^m (f_{\vec{w}, b}(\vec{x}^{(i)}) - y^{(i)})^2 + \frac{\lambda}{2m} \sum_{j=1}^n w_j^2$$

(n = number of features
 m = number of training examples)

* lambda λ = regularization parameter

= penalty for all parameters